

LAPORAN AKHIR (UAS) DATA ANALYTICS

NAMA : Marcellino Wilson Rusli

NIM : 2802417560

1. Review dan evaluation of Data Quality

1. Review kualitas data UTS

Berikut adalah ringkasan dari tahap pembersihan pada proyek UTS. Dataset diambil dari online retail shop yang berpusat pada UK dan terdiri dari 541.909 baris dan 8 kolom yang masih kotor.

Jenis Isu	Detail	Dampak Analisis
Missing Values – CustomerID	135.080 baris (24,93%)	Tidak dapat menganalisis perilaku pelanggan individual secara akurat
Missing Values – Description	1.454 baris (0,27%)	Deskripsi produk tidak lengkap, dapat mengganggu analisis produk
Duplikat Data	5.268 baris	Double-counting pada metrik seperti total penjualan dan jumlah transaksi
Nilai Negatif (Quantity)	10.624 baris	Mencampurkan transaksi pengembalian / error pada data
Outlier (IQR)	Ditemukan di Quantity, UnitPrice, TotalPrice	Mendistorsi mean dan statistik deskriptif lainnya
Inkonsistensi Tipe Data	InvoiceDate bertipe object, bukan datetime	Analisis time-series tidak dapat dilakukan sebelum konversi

2. Data Wrangling

- Penghapusan Missing Values: Baris dengan CustomerID kosong dihapus untuk memastikan setiap transaksi dapat dilacak ke pelanggan spesifik. (kenapa tidak didrop? -> karena analisis membutuhkan perilaku tiap customer pada data)
- Penghapusan Duplikat: Seluruh baris duplikat dihapus menggunakan fungsi `drop_duplicates()` pada seluruh kolom.
- Filtering Nilai Negatif & Zero Price: Baris dengan $Quantity \leq 0$ (retur) dan $UnitPrice = 0$ dieliminasi.
- Konversi Tipe Data: Kolom InvoiceDate dikonversi dari object menjadi datetime64 menggunakan `pd.to_datetime()`.

- Feature Engineering: Kolom TotalPrice dibuat dengan mengalikan $\text{Quantity} \times \text{UnitPrice}$.
- Penghapusan Outlier: Metode IQR diterapkan pada seluruh kolom numerik untuk menghapus nilai ekstrem.

Berikut adalah perbandingan data mentah dan yang sudah dibersihkan :

Kondisi	Jumlah Baris	Persentase
Data sebelum cleaning	541.909	100%
Data setelah cleaning	319.806	59,01%
Data yang dihapus	222.103	40,99%

Disini bisa dilihat banyak sekali data yang dihapus, hampir setengah dari data aslinya. Kami melakukan pembersihan ini dikarenakan beberapa faktor utama sebagai berikut:

- Fokus analisis adalah perilaku pelanggan (RFM, customer spending) ,tanpa CustomerID, transaksi itu tidak bisa diatribusikan ke siapapun
- Untuk analisis RFM khususnya, data tanpa CustomerID memang benar-benar tidak berguna.

2. Advanced Pattern, Trend, and Relationship Analysis

1. Analisis Produk

Rank	Produk	Total Quantity
1	PACK OF 72 RETROSPOT CAKE CASES	14.986
2	ASSORTED COLOUR BIRD ORNAMENT	10.208
3	LUNCH BAG RED RETROSPOT	9.655
4	WHITE HANGING HEART T-LIGHT HOLDER	9.040
5	JAM MAKING SET PRINTED	8.602

Rank	Produk	Total Revenue (GBP)
1	WHITE HANGING HEART T-LIGHT HOLDER	£26,654.16

2	JUMBO BAG RED RETROSPOT	£17,404.30
3	ASSORTED COLOUR BIRD ORNAMENT	£17,251.52
4	LUNCH BAG RED RETROSPOT	£15,995.15
5	NATURAL SLATE HEART CHALKBOARD	£15,553.48

Analisis dua tabel di atas menunjukkan bahwa WHITE HANGING HEART T-LIGHT HOLDER menempati posisi ke-4 dalam kuantitas tetapi menjadi produk #1 dalam revenue. Sebaliknya, PACK OF 72 RETROSPOT CAKE CASES adalah produk terlaris berdasarkan unit tetapi tidak masuk dalam top 5 revenue.

2. Analisis Geografis

Rank	Negara	Total Revenue (GBP)
1	United Kingdom	£3,016,377.15 (92%)
2	Germany	£112,864.73
3	France	£101,926.67
4	EIRE (Ireland)	£83,511.29
5	Spain	£27,070.55

Dominasi UK sebesar 92% dari total revenue wajar karena platform ini berbasis di Inggris.

3. Analisis Korelasi Antar Variabel

- Quantity ↔ TotalPrice ($r = 0,505$): Korelasi positif sedang semakin banyak unit dibeli, semakin tinggi nilai transaksi. Ini adalah hubungan terkuat yang ditemukan.
- UnitPrice ↔ TotalPrice ($r = 0,285$): Korelasi positif lemah harga berpengaruh pada nilai transaksi, tetapi lebih kecil dibanding volume.
- Quantity ↔ UnitPrice ($r = -0,433$): Korelasi negatif sedang produk berharga tinggi cenderung dibeli dalam jumlah kecil, mencerminkan elastisitas harga.

4. RFM Analysis → Segmentasi Pelanggan

Metrik	Recency (hari)	Frequency (transaksi)	Monetary (GBP)
Mean	93,18	3,92	£845.54

Median	51	2	£402.44
Q1 (25%)	18	1	£171.97
Q3 (75%)	145	4	£957.14
Maximum	374	193	£70,372.02

Variasi besar pada Frequency (std = 6,81) dan Monetary (std = £1,761.72) mengindikasikan segmentasi pelanggan yang tajam. Korelasi Frequency–Monetary sebesar 0,79 (sangat kuat) membuktikan bahwa pelanggan yang lebih sering bertransaksi secara konsisten menghasilkan revenue lebih tinggi

3. Evaluation of Analytical Methods and Metrics

1. Teknik Analitik yang Digunakan

Berikut adalah teknik yang digunakan pada analisis proyek ini :

- Statistik Deskriptif: Mean, median, standar deviasi, dan persentil digunakan untuk memahami distribusi dasar variabel numerik (Quantity, UnitPrice, TotalPrice).
- Analisis Distribusi (Histogram & Boxplot): Memvisualisasikan distribusi data dan mengidentifikasi skewness. Ketiga variabel numerik menunjukkan distribusi right-skewed yang konsisten dengan data ritel pada umumnya.
- Correlation Matrix (Pearson): Mengukur kekuatan dan arah hubungan linear antar variabel numerik. Dipilih karena variabel bersifat kontinu setelah pembersihan outlier.
- Geographic Aggregation: Penjualan dikelompokkan berdasarkan negara untuk analisis distribusi pasar.
- RFM Scoring: Pelanggan dikuantifikasi berdasarkan tiga dimensi perilaku untuk segmentasi strategis.
- IQR-based Outlier Removal: Batas whisker $1,5 \times \text{IQR}$ digunakan sebagai threshold standar statistik untuk memisahkan outlier dari distribusi inti.

2. Metrik Evaluasi dan Efektivitasnya

Metrik	Nilai / Hasil	Interpretasi
Korelasi Pearson (Qty–Total)	$r = 0,505$	Korelasi positif sedang; Quantity adalah prediktor utama TotalPrice

Korelasi Pearson (Price–Total)	$r = 0,285$	Pengaruh UnitPrice terhadap TotalPrice lebih lemah dibanding volume
Korelasi RFM (Freq–Monetary)	$r = 0,79$	Hubungan sangat kuat; frekuensi transaksi mendorong total pengeluaran
Reduksi Data (IQR Cleaning)	–40,99%	Trade-off diterima; data bersih lebih representatif untuk analisis
Skewness Distribusi	Right-skewed (mean > median)	Mayoritas transaksi bernilai kecil; sebagian kecil bernilai sangat besar

3. Keterbatasan pada analisis

- Reduksi data 40,99%: Meskipun diperlukan untuk akurasi, penghapusan outlier berpotensi menghilangkan informasi tentang pelanggan premium atau transaksi bulk yang justru signifikan secara bisnis.
- Korelasi bukan kausalitas: Nilai korelasi Pearson hanya mengukur hubungan linear. Hubungan non-linear antar variabel tidak tertangkap oleh metode ini.
- Data tidak lengkap pada Desember: Penurunan tajam di akhir dataset kemungkinan besar bukan tren aktual melainkan ketidaklengkapan data, yang dapat memengaruhi akurasi model prediksi musiman jika dikembangkan lebih lanjut.
- Tidak ada model prediktif: Analisis ini bersifat deskriptif dan eksploratif. Tidak ada model machine learning yang digunakan, sehingga validasi prediktif (RMSE, accuracy, dll.) tidak dapat dilakukan.
- Bias geografis: Dominasi UK (92%) membuat analisis geografis kurang representatif untuk menggambarkan perilaku pelanggan internasional secara mendalam.

4. Actionable Recommendations & Decision Support

1. Ringkasan Temuan EDA

Insight pada EDA:

- Mayoritas pelanggan (>75%) melakukan pembelian dengan total pengeluaran di bawah £957. Namun, terdapat segmen kecil pelanggan premium dengan pengeluaran hingga £70.372, yang berkontribusi signifikan terhadap total revenue.
- Produk dengan volume penjualan tinggi tidak selalu menghasilkan revenue tertinggi harga per unit adalah faktor pembeda.
- Frekuensi transaksi berkorelasi sangat kuat ($r = 0,79$) dengan total pengeluaran pelanggan.
- utama Pasar Inggris menjadi fokus dalam groceries ini karena paling mendominasi

2. Rekomendasi Bisnis Berbasis Data

Dari analisis yang telah dilakukan, ada dua temuan kunci yang bisa dipakai untuk mengambil keputusan bisnis. Pertama, pelanggan yang berbelanja dengan nilai besar memberi kontribusi yang berarti pada keseluruhan pendapatan perusahaan. Makanya, penting untuk mengutamakan cara mempertahankan pelanggan, seperti program setia, tawaran spesial, dan layanan yang disesuaikan guna menjaga aliran pemasukan dan membuat pelanggan semakin loyal.

Kedua, sebagian besar transaksi dan pendapatan perusahaan datang dari Inggris, menandakan bahwa pasar lokal masih jadi sumber pemasukan utama. Hasil ini mengindikasikan perusahaan perlu terus memperkuat posisinya di pasar Inggris dengan cara meningkatkan pelayanan, menyempurnakan strategi pemasaran, dan membuat produk yang pas dengan keinginan konsumen. Dengan tetap menjaga kekuatan di pasar utama dan meningkatkan retensi dari pelanggan berharga tinggi, perusahaan bisa mempertahankan pertumbuhan pendapatannya dalam jangka panjang.

3. Implikasi bagi stakeholder

Stakeholder	Insight Relevan	Tindakan yang Direkomendasikan
Tim Marketing	Peak sales Nov	Jadwalkan campaign pre-holiday mulai September
Tim Sales / CRM	RFM: high-value customers teridentifikasi	Implementasikan program loyalitas
Tim Supply Chain	Produk bestseller & peak demand Nov	Tingkatkan stok produk unggulan (PACK OF 72 RETROSPOT CAKE CASES) menjelang Q4
Manajemen Strategis	Potensi pasar inggris	Fokus pada market di UK